PROYECTO FINAL · APRENDIZAJE POR REFUERZO

Aterrizaje con propulsores discretos

Un PID en cascada, DQN y Double DQN entrenados desde cero, y redes asistidas por demostraciones, comparados en el mismo simulador y sobre los mismos 388 casos reservados.

98 / 100
PID en la prueba reservada

96 / 100
DQN asistido por demostraciones

0 / 100
DQN y Double DQN desde cero

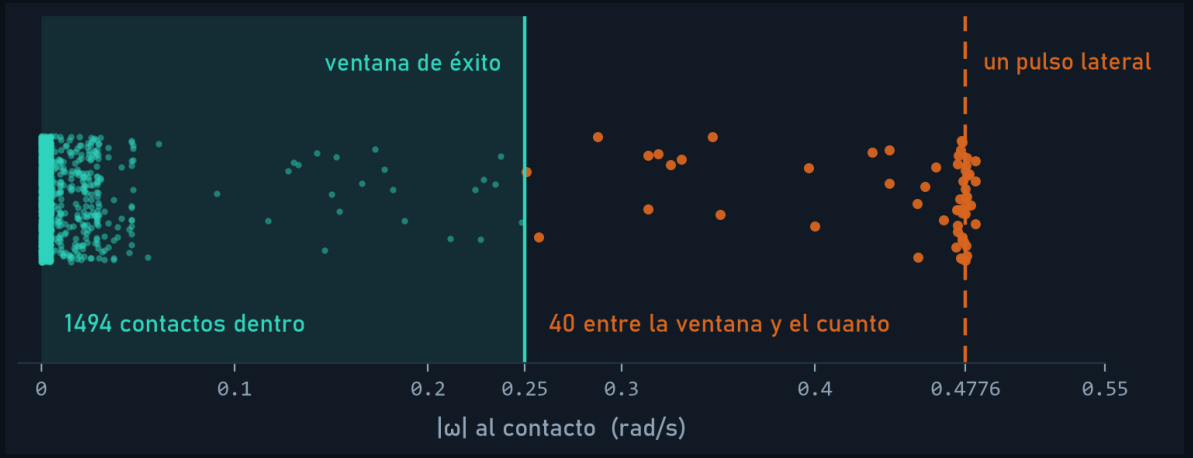
Diego Linares, Andy Fuentes y Diederich Solís · Aprendizaje por Refuerzo, Universidad del Valle de Guatemala · noviembre de 2026

EL PROBLEMA

Aterrizar exige acertar seis variables a la vez

Al contacto	Ventana	Unidad
Error horizontal |x|	≤ 1.5	m
Velocidad lateral |vx|	≤ 0.7	m/s
Velocidad vertical vy	−1 a 0	m/s
Inclinación |θ|	≤ 0.12	rad
Velocidad angular |ω|	≤ 0.25	rad/s
Apoyos en plataforma	± 2.5	m

Dónde cayeron 1 552 contactos reales



Los 58 fallos de los cuatro controladores que sí aterrizan son **todos por ω**, y se amontonan en una banda muy concreta.

Vehículo de 100 kg · empuje 1800 / 600 / 600 N · gas 18 000 N·s · 8 acciones a 20 Hz · física a 200 Hz

ANÁLISIS · EL CUELLO DE BOTELLA

Un solo pulso lateral vale casi el doble de la ventana

0.4776

rad/s que imprime un pulso de 0.05 s

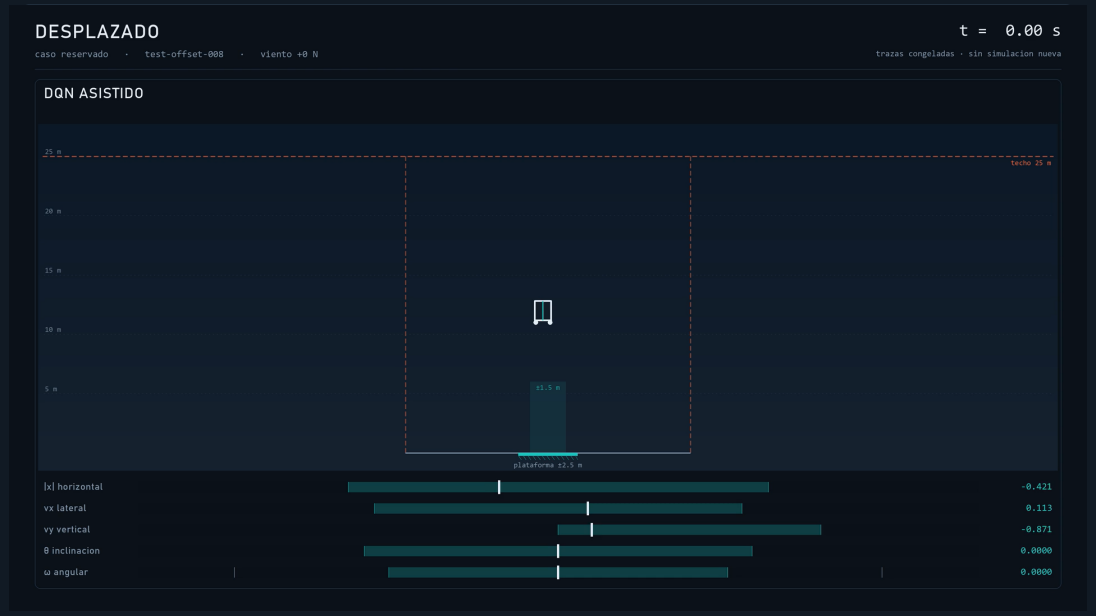
0.25

rad/s que permite la ventana

$$\Delta\omega = 600\ \text{N} \times 0.6\ \text{m} \div 37.67\ \text{kg·m}^2 \times 0.05\ \text{s}$$

Desde $\omega \approx 0$ solo se alcanzan múltiplos de 0.4776. Cumplir la ventana exige un número **exactamente balanceado** de pulsos.

Por eso los dos fallos del PID son por ω, y por eso un explorador aleatorio nunca encuentra un aterrizaje.



Verificado contra una integración RK4 independiente · 40 de los 58 fallos caen entre la ventana y el cuanto

PROPUESTA DE SOLUCIÓN

Tres familias de controlador, un solo entorno

01

PID en cascada

Tres lazos anidados y asignación del empuje continuo a una de las ocho acciones por mínimos cuadrados.

sin aprendizaje
ganancias a mano

02

DQN y Double DQN desde cero

Red 9 → 128 → 128 → 8, replay, red objetivo y ε-greedy. Es lo que prometía el anteproyecto.

5 campañas
550 000 pasos

03

Asistido por demostraciones

Imitación del PID, luego TD y margen supervisado. En inferencia actúa solo la red.

84 882 transiciones
30 000 pasos propios

Física, recompensa, acciones y criterios de éxito idénticos para los tres · verificados por SHA-256 antes de cada corrida

RESULTADO NEGATIVO · CINCO CAMPAÑAS

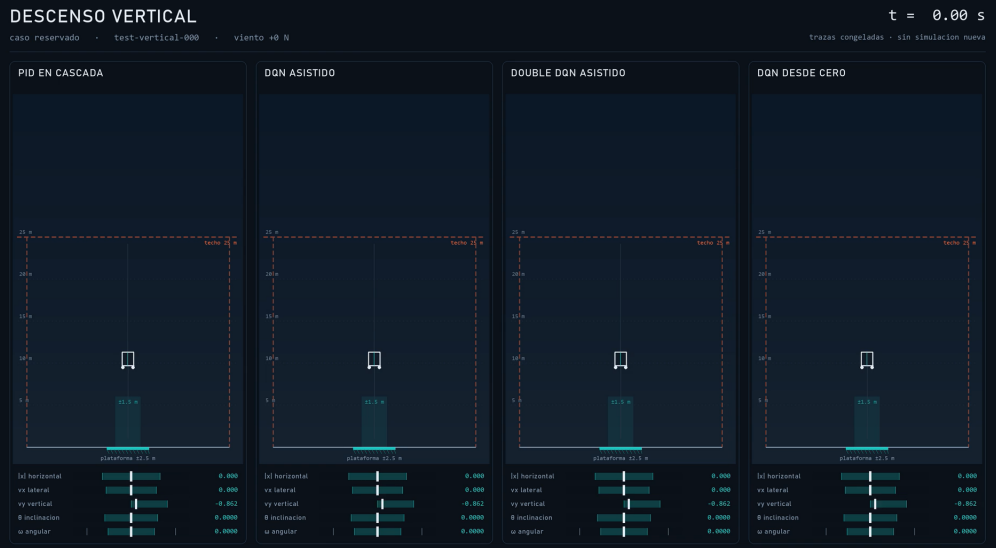
El RL desde cero no aterrizó ni una vez

0
terminaciones positivas en 50 000 transiciones

32 / 32
salidas por el techo al final del piloto

3
éxitos con exploración ponderada, ninguno en greedy



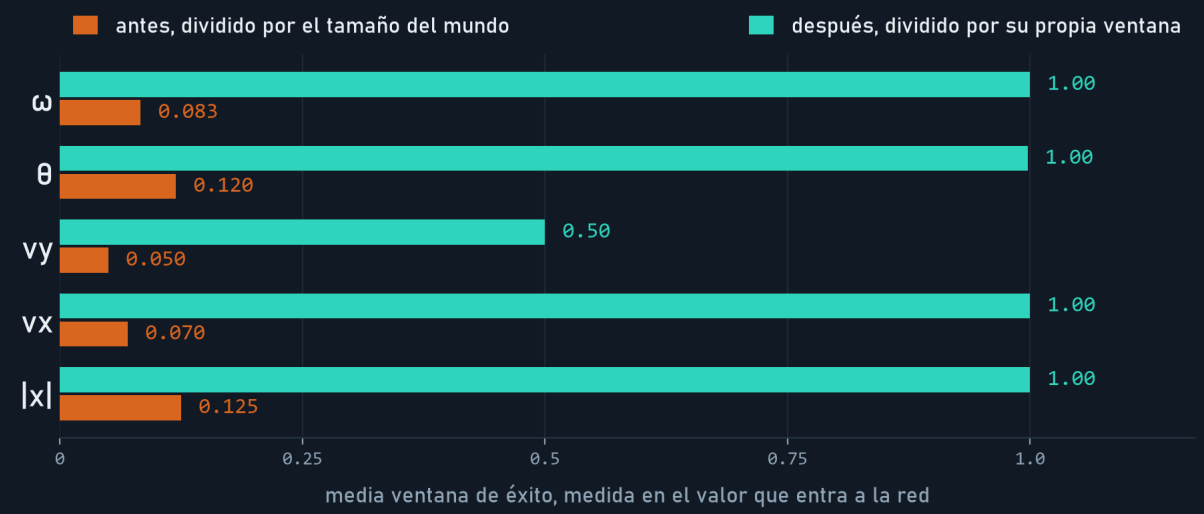


piloto_100k · ablacion_lr1e4 · ablacion_beta10 · piloto_curriculum · experimento_exploracion

DESCRIPCIÓN DE LA SOLUCIÓN

Tres cambios, ninguno a la recompensa

1 · Normalizar por las ventanas, no por el mundo



ω/3 → ω/0.25 · vx/10 → vx/0.7 · x/12 → x/1.5

2 · Demostraciones permanentes

84 882

transiciones de 1 005 aterrizajes del PID, mezcladas con el replay propio en cada minibatch.

3 · Cubrir la altura

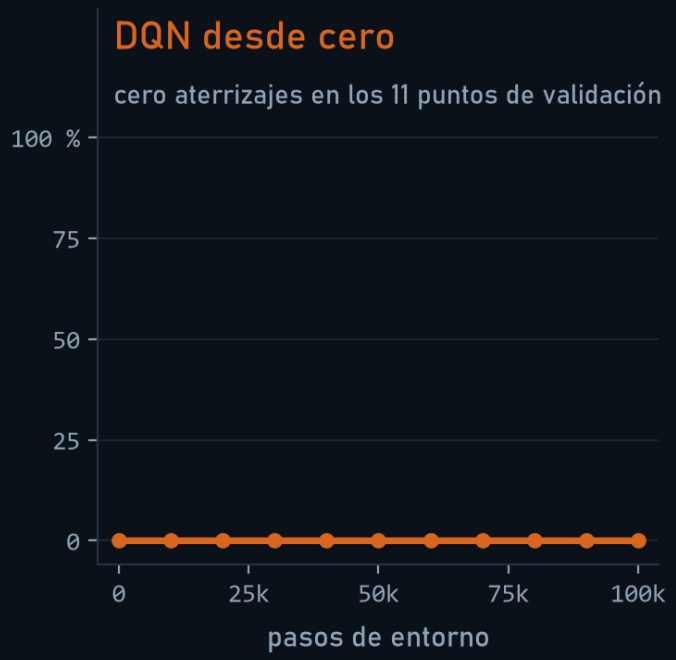
0 / 32 →**32 / 32**

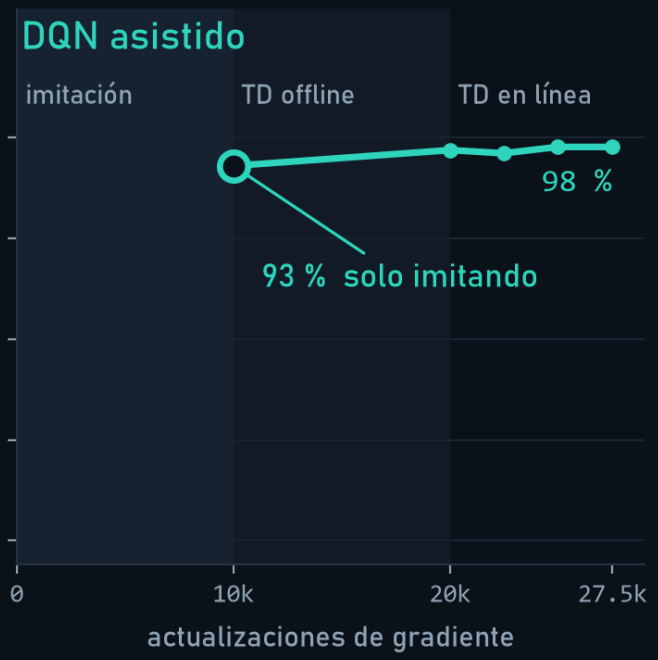
Solo con demostraciones de 1.6 a 2.4 m no transfería. Mitad cerca del suelo y mitad desde 8 a 13 m sí.

Transformación invertible de las mismas nueve variables · recompensa, física y criterios sin tocar · en inferencia actúa solo la red

APRENDIZAJE · CURVAS DE ENTRENAMIENTO

Casi todo el rendimiento llega imitando





93 %

en desarrollo al terminar la fase de pura imitación, antes de la primera actualización TD

+5

puntos es lo que añaden las 15 000 actualizaciones siguientes de TD y margen

Los dos paneles comparten la escala de éxito. Los ejes horizontales no: las unidades son distintas.

641 evaluaciones sobre los 128 casos de desarrollo · artifacts/recovery_v1/dqn_coverage_v2_seed42/evaluations.csv

RESULTADOS · PRUEBA CONGELADA, EJECUTADA UNA VEZ

Seis métodos, 388 casos, 2 328 episodios

Método	Reservados	Complemento	Fallos
PID en cascada	98 / 100	287 / 288	3 ω
DQN asistido	96 / 100	275 / 288	17 ω
Double DQN asistido	94 / 100	266 / 288	22 ω
DQN asistido, semilla 43	100 / 100	277 / 288	11 ω
DQN desde cero	0 / 100	0 / 288	impactos
Double DQN desde cero	0 / 100	0 / 288	impactos



El complemento incluye viento de 0, ±20 y ±40 N que ninguna red vio en entrenamiento. La segunda semilla se conserva como sensibilidad: **no se eligió después de ver la prueba**.

242 465 pasos de entorno · 53 hashes verificados antes de cada método · reproducido de forma independiente en otra máquina

ABLACIÓN · 288 CASOS NUEVOS, PROTOCOLO CONGELADO APARTE

Las actualizaciones TD no aportaron nada sobre la imitación sola

279 / 288

Imitación sola, semilla 42
solo entropía cruzada, cero TD

276 / 288

DQN asistido, semilla 42
imitación más TD y margen

278 / 288

PID en cascada
referencia clásica

Comparación emparejada caso por caso · McNemar exacto

Par comparado	Solo asistido	Solo imitación	p
DQN, semilla 42	7	10	0.629
Double DQN, semilla 42	8	16	0.152
DQN, semilla 43	17	11	0.345
Entre semillas de la misma familia	16	7	0.093

La variación entre semillas es mayor que la variación entre familias. Con una semilla por configuración no se puede atribuir a TD una diferencia de tres o seis aterrizajes.

Mismos pesos iniciales, mismas demostraciones, mismo orden de minibatches · docs/ablacion_imitacion.md

CONCLUSIONES Y ALCANCE

El límite no fue el algoritmo, fue la señal

98 / 100
El control clásico gana, y no hace falta adornarlo.

+200.8
El fracaso desde cero está diagnosticado, no asumido.

93 %
Lo que hizo aterrizar a la red fue imitar al profesor.

0.4776
El techo real es el espacio de acciones, no el algoritmo.

No se puede afirmar

- Que aprender desde cero sea inviable aquí: lo es con este presupuesto y esta recompensa
- Que el TD aporte sobre la imitación: $p \geq 0.15$ en las tres comparaciones
- Nada estadístico: una semilla principal por algoritmo

Trabajo futuro

- Recompensa terminal graduada en vez de −100 plano
- Tres semillas por configuración
- Propulsores de media potencia o decisiones a 40 Hz

Bibliografía

- Mnih et al. (2015), Nature 518
- Van Hasselt et al. (2016), *Double Q-learning*
- Hester et al. (2017), *Learning from Demonstrations*
- Towers et al. (2024), *Gymnasium*

118 pruebas · prueba final congelada por hash y ejecutada una vez · reproducida en otra máquina con las doce cifras idénticas · github.com/Andyfer004/Proyecto-RL